

Pemodelan Komputasi dan Analisis Numerik


SPL, SPNL, Regresi Linear,
dan Pencocokan Kurva

MA25-31017 ■ Pertemuan 2
Program Studi Matematika
Institut Teknologi Sumatera

Dosen Pengampu

Rifky Fauzi

Dear Michiko Mutiara Noor



Dari data ke model: menentukan parameter secara numerik.

Benang Merah: Semuanya Kembali ke $F(\mathbf{x}) = 0$

Ingat Pertemuan 1

Pencarian akar mencari x sehingga $f(x) = 0$: **tebak**, **evaluasi**, **perbaiki**, lalu ukur galat dan periksa konvergensi. Hari ini pola yang sama muncul kembali dalam dimensi yang lebih tinggi.

Empat topik dengan satu ide

Topik	Bentuk residual
SPL	$A\mathbf{x} - \mathbf{b} = \mathbf{0}$
SPNL	$F(\mathbf{x}) = 0$
Regresi linear	$\nabla S_r = 0 \Rightarrow$ SPL normal
Curve fitting	$\nabla S_r = 0$, nonlinear


Yang berulang sepanjang MK

- **Iterasi**: tebakan awal diperbaiki bertahap.
- **Galat**: $\varepsilon_a = \left| \frac{x^{(k)} - x^{(k-1)}}{x^{(k)}} \right| 100\%$.
- **Konvergensi**: kapan boleh berhenti, dan kapan justru divergen.

Alur pertemuan ini

SPL $\rightarrow$ SPNL $\rightarrow$ Regresi $\rightarrow$ Curve Fitting

Dari Hukum Konservasi Massa Menuju SPL



Skema mengikuti Chapra & Canale (2015): laju massa lewat pipa = $Q \cdot c$ dari arah aliran berasal.

Neraca massa tiap reaktor

Pada keadaan tunak, untuk setiap reaktor berlaku

$$\sum (\text{massa masuk}) = \sum (\text{massa keluar}).$$

Satu reaktor menghasilkan satu persamaan; konsentrasi c_1, c_2, c_3 saling terkait.

Hasilnya

Sistem persamaan **linear** dalam c_1, c_2, c_3 . Untuk jaringan besar (puluhan hingga ribuan simpul), penyelesaian manual tidak realistis.

Contoh lain

Rangkaian listrik, struktur rangka, diskretisasi PDB/PDE, dan persamaan normal pada regresi.

Sistem Persamaan Linear: Formulasi

Bentuk umum

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1$$

$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2$$

$$\vdots$$

$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m$$

dengan $a_{ij}, b_i \in \mathbb{R}$. Secara matriks:

$$A\vec{x} = \vec{b}.$$

Dua keluarga metode

Langsung

Eliminasi Gauss, dekomposisi LU: solusi dalam langkah berhingga

Iteratif

Jacobi, Gauss-Seidel: barisan hampiran yang (semoga) konvergen

Mengapa iteratif?

Untuk matriks **besar dan jarang** (sparse), metode iteratif lebih hemat memori dan sering lebih cepat. Polanya juga persis metode pencarian akar: tebak, perbaiki, ukur galat.

Fokus pertemuan ini: metode iteratif, sebagai jembatan menuju SPNL dan regresi.

Metode Jacobi: Algoritma

Ide

Isolasi x_i dari persamaan ke- i , lalu hitung semua komponen **serentak** memakai nilai iterasi sebelumnya:

$$x_i^{(k+1)} = \frac{b_i - \sum_{j \neq i} a_{ij} x_j^{(k)}}{a_{ii}}, \quad i = 1, \dots, n.$$

Seluruh ruas kanan hanya memakai indeks (k) .

Kriteria berhenti

$$|\varepsilon_{a,i}| = \left| \frac{x_i^{(k+1)} - x_i^{(k)}}{x_i^{(k+1)}} \right| 100\% < \varepsilon_s$$

untuk **semua** i ; sediakan juga iterasi maksimum.

Langkah

1. Tetapkan toleransi ε_s .
2. Tetapkan tebakan awal, umumnya $x_i^{(0)} = 0$.
3. Hitung seluruh $x_i^{(k+1)}$ dengan rumus di samping.
4. Hitung $|\varepsilon_{a,i}|$ tiap komponen.
5. Berhenti jika semua $|\varepsilon_{a,i}| < \varepsilon_s$; jika belum, kembali ke langkah 3.

Catatan

Butuh $a_{ii} \neq 0$. Bila ada diagonal nol, lakukan penukaran baris (pivoting) lebih dulu.

Contoh Jacobi: Lengkapi Iterasi Berikutnya

Sistem

$$3x_1 - 0.1x_2 - 0.2x_3 = 7.85$$

$$0.1x_1 + 7x_2 - 0.3x_3 = -19.3$$

$$0.3x_1 - 0.2x_2 + 10x_3 = 71.4$$

Target $\varepsilon_{a,i} < 0.001\%$, mulai dari $x^{(0)} = 0$.

Formula iteratif

$$x_1^{(k+1)} = \frac{7.85 + 0.1x_2^{(k)} + 0.2x_3^{(k)}}{3}$$

$$x_2^{(k+1)} = \frac{-19.3 - 0.1x_1^{(k)} + 0.3x_3^{(k)}}{7}$$

$$x_3^{(k+1)} = \frac{71.4 - 0.3x_1^{(k)} + 0.2x_2^{(k)}}{10}$$

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\max \varepsilon_{a,i} $
0	0	0	0	—
1	2.61666667	-2.75714286	7.14000000	100%
2	3.00076190	-2.48852381	7.00635714	12.800%
3	...	...	...	...
4	...	...	...	...

Aktivitas kelas

Hitung iterasi 3 dan 4, lalu lanjutkan di Excel hingga toleransi tercapai. Bandingkan dengan solusi eksak $x = (3, -2.5, 7)$.

Perhatikan

Iterasi 2 memakai **seluruh** nilai iterasi 1, termasuk $x_1^{(1)}$ yang sebenarnya sudah tersedia lebih dulu.

Metode Gauss-Seidel: Pakai Informasi Terbaru

Modifikasi dari Jacobi

Begitu $x_1^{(k+1)}$ selesai dihitung, langsung pakai untuk menghitung $x_2^{(k+1)}$, dan seterusnya:

$$x_i^{(k+1)} = \frac{b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)}}{a_{ii}}.$$

Beda satu kata dan beda perilaku

Jacobi	semua komponen dari iterasi (k)
Gauss-Seidel	komponen $j < i$ sudah dari iterasi ($k + 1$)

Konsekuensi praktis

- ▶ Umumnya konvergen lebih cepat pada sistem yang sama.
- ▶ Hanya perlu satu vektor kerja (hemat memori).
- ▶ Hasilnya bergantung pada **urutan persamaan**; Jacobi tidak.

Hubungan ke titik tetap

Keduanya berbentuk $\mathbf{x}^{(k+1)} = G(\mathbf{x}^{(k)})$ — versi berdimensi n dari metode titik tetap di Pertemuan 1.

Contoh Gauss-Seidel: Sistem yang Sama

Formula iteratif

$$x_1^{(k+1)} = \frac{7.85 + 0.1x_2^{(k)} + 0.2x_3^{(k)}}{3}$$

$$x_2^{(k+1)} = \frac{-19.3 - 0.1x_1^{(k+1)} + 0.3x_3^{(k)}}{7}$$

$$x_3^{(k+1)} = \frac{71.4 - 0.3x_1^{(k+1)} + 0.2x_2^{(k+1)}}{10}$$

Yang berwarna adalah nilai yang *baru saja* dihitung.

Iterasi 1 secara rinci

$$x_1^{(1)} = \frac{7.85 + 0.1(0) + 0.2(0)}{3} = 2.6166667$$

$$x_2^{(1)} = \frac{-19.3 - 0.1(2.6167) + 0.3(0)}{7} = -2.7945238$$

$$x_3^{(1)} = \frac{71.4 - 0.3(2.6167) + 0.2(-2.7945)}{10} = 7.0056095$$

Nilai di dalam kurung dibulatkan agar muat; perhitungan tetap memakai presisi penuh.

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$	$\max \epsilon_{a,i} $
0	0	0	0	—
1	2.61666667	-2.79452381	7.00560952	100%
2	...	...	...	...
3	...	...	...	...

Aktivitas kelas

Lengkapi iterasi 2 dan 3, lalu bandingkan jumlah iterasi Gauss-Seidel dengan Jacobi untuk mencapai ϵ_s yang sama. Sajikan plot ϵ_a terhadap iterasi seperti pada Pertemuan 1.

Diskusi

Apakah percepatan ini berlaku untuk semua sistem, atau hanya untuk kelas matriks tertentu?

Kapan Metode Iteratif untuk SPL Konvergen?

Syarat cukup yang mudah dipakai

Matriks **dominan diagonal** secara tegas:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}| \quad \text{untuk setiap } i.$$

Jika terpenuhi, Jacobi dan Gauss-Seidel dijamin konvergen dari sebarang tebakan awal.

Perhatikan arah implikasinya

Ini syarat **cukup**, bukan syarat perlu. Sistem yang gagal memenuhinya masih mungkin konvergen; yang tidak dijamin hanyalah jaminannya.

Rumusan matriks

Tulis $\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)} + \mathbf{c}$. Barisan konvergen jika dan hanya jika radius spektral

$$\rho(T) = \max_i |\lambda_i(T)| < 1,$$

dan makin kecil $\rho(T)$, makin cepat konvergensinya.

Analogi Pertemuan 1

Persis syarat $|g'(x)| < 1$ pada metode titik tetap. $\rho(T)$ adalah versi matriksnya.

Latihan: periksa dominansi diagonal sistem pada dua slide sebelumnya, lalu hitung $\rho(T)$ untuk Jacobi dan Gauss-Seidel.

Sistem Persamaan Nonlinear

Bentuk umum

$$f_1(x_1, x_2, \dots, x_n) = 0$$

$$f_2(x_1, x_2, \dots, x_n) = 0$$

$$\vdots$$

$$f_m(x_1, x_2, \dots, x_n) = 0$$

dengan setidaknya satu f_i bukan fungsi linear. Ringkasnya $F(\mathbf{x}) = \mathbf{0}$.

Contoh

$$x_1 x_2 + x_2^2 x_3 + x_3^2 + 2 = 0$$

$$x_1^2 + x_2 x_3^2 + x_2^2 + 3 = 0$$

$$x_1 x_3 + x_2 x_3^2 + x_3^2 + 4 = 0$$

Apa yang hilang dibanding SPL

- ▶ Tidak ada rumus tertutup seperti eliminasi Gauss.
- ▶ Solusi bisa **tidak ada, tunggal, atau banyak**.
- ▶ Konvergensi bergantung kuat pada tebakan awal.

Strateginya

Gunakan kembali gagasan Newton-Raphson: dekati fungsi dengan model linear di sekitar tebakan, selesaikan model linear itu, lalu ulangi. Model linear tersebut berbentuk **SPL**.

Masalah Nonlinear di Kecerdasan Buatan

Satu neuron dengan aktivasi sigmoid

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad y = \sigma(wx + b),$$

dengan w bobot dan b bias. Diberikan tiga data latih

$$(0, 0.1), \quad (1, 0.9), \quad (1.5, 0.8).$$

Agar model “belajar”

Dicari w dan b sehingga

$$\begin{cases} \sigma(b) = 0.1 \\ \sigma(w + b) = 0.9 \\ \sigma(1.5w + b) = 0.8 \end{cases}$$

Sistem ini nonlinear karena kehadiran σ .

Bentuk residual

$$F(b, w) = \begin{bmatrix} \sigma(b) - 0.1 \\ \sigma(w + b) - 0.9 \\ \sigma(1.5w + b) - 0.8 \end{bmatrix} = \vec{0}.$$

Perhatikan

Ada **3 persamaan** tetapi hanya **2 parameter**. Sistem seperti ini umumnya tidak punya solusi eksak, sehingga yang dicari adalah parameter yang **memperkecil** $\|F\|$ — inilah pintu masuk ke regresi nonlinear dan Gauss-Newton di paruh kedua pertemuan.

Kaitan project

Pelatihan model data-driven pada dasarnya penyelesaian sistem nonlinear berdimensi besar secara iteratif.

Linearisasi dengan Deret Taylor

Ekspansi orde satu untuk fungsi banyak variabel

$$f_i(x_1 + \Delta x_1, \dots, x_n + \Delta x_n) \approx f_i(x_1, \dots, x_n) + \Delta x_1 \frac{\partial f_i}{\partial x_1} + \Delta x_2 \frac{\partial f_i}{\partial x_2} + \dots + \Delta x_n \frac{\partial f_i}{\partial x_n}.$$

Syaratkan langkah menuju solusi

Jika $\mathbf{x} + \Delta \mathbf{x}$ adalah solusi, ruas kiri bernilai nol, sehingga

$$-f_i(\mathbf{x}) = \sum_{j=1}^n \Delta x_j \frac{\partial f_i}{\partial x_j}, \quad i = 1, \dots, m.$$

Yang kita peroleh

Persamaan di samping **linear dalam** Δx_j . Masalah nonlinear berubah menjadi barisan masalah linear — persis seperti Newton-Raphson satu variabel yang mengganti kurva dengan garis singgung.

Harga yang dibayar

Aproksimasi ini hanya baik di sekitar $\mathbf{x}$, sehingga langkahnya harus diulang dan tebakan awal tetap menentukan.

SPL dari Deret Taylor: Matriks Jacobi

$$\underbrace{\begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}}_{A \text{ (matriks Jacobi)}} \underbrace{\begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \vdots \\ \Delta x_n \end{bmatrix}}_{\Delta X} = \underbrace{\begin{bmatrix} -f_1 \\ -f_2 \\ \vdots \\ -f_m \end{bmatrix}}_{-f}$$

$$A \Delta X = -f$$

Skema iterasi

Pada langkah ke- n :

1. Susun A^n dan f^n di titik x^n .
2. Selesaikan SPL $A^n \Delta X^n = -f^n$.
3. Perbarui

$$x_i^{n+1} = x_i^n + \Delta x_i^n.$$

4. Ulangi sampai

$$\frac{|x_i^{n+1} - x_i^n|}{|x_i^{n+1}|} < \varepsilon_a.$$

Inilah alasan urutannya

SPL dipelajari lebih dulu karena **setiap** langkah SPNL adalah satu penyelesaian SPL.

Contoh SPNL: Iterasi Pertama

Sistem dan turunan parsialnya

$$f_1 = x_1 x_2 + x_2^2 x_3 + x_3^2 + 2$$

$$f_2 = x_1^2 + x_2 x_3^2 + x_2^2 + 3$$

$$f_3 = x_1 x_3 + x_2 x_3^2 + x_3^2 + 4$$

$$A = \begin{bmatrix} x_2 & x_1 + 2x_2 x_3 & x_2^2 + 2x_3 \\ 2x_1 & x_3^2 + 2x_2 & 2x_2 x_3 \\ x_3 & x_3^2 & x_1 + 2x_2 x_3 + 2x_3 \end{bmatrix}$$

Tebakan awal

$$x_1^0 = x_2^0 = x_3^0 = 1, \text{ sehingga}$$

$$A^0 = \begin{bmatrix} 1 & 3 & 3 \\ 2 & 3 & 2 \\ 1 & 1 & 5 \end{bmatrix}, \quad -f^0 = \begin{bmatrix} -5 \\ -6 \\ -7 \end{bmatrix}.$$

Selesaikan SPL-nya

$$\begin{bmatrix} 1 & 3 & 3 \\ 2 & 3 & 2 \\ 1 & 1 & 5 \end{bmatrix} \begin{bmatrix} \Delta x_1^0 \\ \Delta x_2^0 \\ \Delta x_3^0 \end{bmatrix} = \begin{bmatrix} -5 \\ -6 \\ -7 \end{bmatrix} \Rightarrow \begin{bmatrix} \Delta x_1^0 \\ \Delta x_2^0 \\ \Delta x_3^0 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \\ -1 \end{bmatrix}$$

Perbarui

$$\begin{bmatrix} x_1^1 \\ x_2^1 \\ x_3^1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} + \begin{bmatrix} -2 \\ 0 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$$

Aktivitas kelas

Lakukan iterasi ke-2: susun A^1 dan f^1 di $x^1 = (-1, 1, 0)$, selesaikan SPL-nya, lalu hitung ε_a tiap komponen. Perhatikan apakah A^1 masih taksingular.

Pencocokan Kurva: Model Menghampiri Data

Model kandidat

Linear: $f(x) = a + bx$


Polinom: $f(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$

Data selalu memuat ketidakpastian

Kesalahan model pada tiap titik didefinisikan

$$e_i = y_i - f(x_i).$$

Koefisien model dipilih agar kumpulan e_i ini **kecil** menurut ukuran tertentu: rata-rata absolut, rata-rata kuadrat, dan seterusnya.



Bedakan dua tujuan

Regresi menghampiri tren data yang berderau. **Interpolasi** memaksa kurva melewati semua titik — pilihan yang buruk bila data mengandung galat pengukuran.

Regresi Linear: Least-Square Menghasilkan SPL

Fungsi objektif

$$S_r = \sum_{i=1}^N e_i^2 = \sum_{i=1}^N (y_i - a - bx_i)^2.$$

Cari a dan b yang meminimumkan S_r .

Syarat titik kritis

$$\frac{\partial S_r}{\partial a} = -2 \sum (y_i - a - bx_i) = 0$$

$$\frac{\partial S_r}{\partial b} = -2 \sum (y_i - a - bx_i)x_i = 0$$

Persamaan normal

$$Na + \left(\sum x_i \right) b = \sum y_i$$

$$\left(\sum x_i \right) a + \left(\sum x_i^2 \right) b = \sum x_i y_i$$

atau

$$\begin{bmatrix} N & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}.$$

Benang merah lagi

Regresi linear **adalah** sebuah SPL. Syarat optimum $\nabla S_r = \mathbf{0}$ tak lain masalah “mencari akar” pada gradien.

Contoh Regresi Linear: Lengkapi Tabelnya

x_i	y_i	x_i^2	$x_i y_i$
1	0.5	1	0.5
2	2.5	4	5
3	2.0	9	6
4	4.0		
5	3.5		
6	6.0		
7	5.5		
$\sum = 28$		$\sum = 24$	

Langkah kerja

Lengkapi kolom x_i^2 dan $x_i y_i$, jumlahkan, lalu susun dan selesaikan

$$\begin{bmatrix} 7 \\ 28 \end{bmatrix} \begin{bmatrix} 28 \\ \sum x_i^2 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} 24 \\ \sum x_i y_i \end{bmatrix}.$$

Hasil yang diharapkan

$$a = \frac{1}{14} \approx 0.07142, \quad b = \frac{47}{56} \approx 0.83929,$$

$$f(x) = 0.07142 + 0.83929 x.$$

Lanjutan

Hitung $\bar{y}$, lalu

$$S_t = \sum (y_i - \bar{y})^2, \quad S_r = \sum (y_i - a - bx_i)^2, \quad r^2 = \frac{S_t - S_r}{S_t}.$$

Kualitas Model: S_t , S_r , dan r^2

Dua pembanding

$$S_t = \sum (y_i - \bar{y})^2$$

sebaran data terhadap **rata-rata**: model paling sederhana yang mungkin.

$$S_r = \sum (y_i - a - bx_i)^2$$

sebaran data terhadap **garis regresi**.

Koefisien determinasi

$$r^2 = \frac{S_t - S_r}{S_t}$$

mengukur seberapa besar perbaikan yang diberikan garis dibanding sekadar memakai rata-rata.

Membaca nilainya

$r^2 = 1$	$S_r = 0$: garis melewati tepat semua titik data
$r^2 = 0$	$S_t = S_r$: garis tidak lebih baik daripada rata-rata

Jangan berhenti di r^2

Nilai r^2 tinggi tidak menjamin modelnya tepat: ia bisa naik hanya karena parameter ditambah, dan ia buta terhadap pola sisa (residual) yang jelas melengkung. Selalu periksa plot residual, bukan hanya satu angka.

Untuk data contoh: $\bar{y} = 3.4286$, $S_t = 22.714$, $S_r = 2.991$, sehingga $r^2 \approx 0.868$.

Linearisasi Relasi Nonlinear

Model asli	Transformasi	Bentuk linear
$y = \alpha_1 e^{\beta_1 x}$	$\ln y$ vs x	kemiringan β_1 , intersep $\ln \alpha_1$
$y = \alpha_2 x^{\beta_2}$	$\log y$ vs $\log x$	kemiringan β_2 , intersep $\log \alpha_2$
$y = \alpha_3 \frac{x}{\beta_3 + x}$	$1/y$ vs $1/x$	kemiringan β_3/α_3 , intersep $1/\alpha_3$

Gagasannya

Ubah variabel sehingga relasi menjadi garis lurus, lalu pakai regresi linear biasa, dan kembalikan hasilnya ke parameter asli.

Harga yang dibayar

Transformasi juga mengubah **bobot galat**. Least-square pada $\ln y$ meminimumkan galat relatif pada y , bukan galat absolutnya, sehingga hasilnya *tidak sama* dengan least-square pada data asli.

Karena itu

Linearisasi bagus sebagai penghasil tebakan awal; pencocokan akhir sebaiknya dikerjakan langsung pada model nonlinearnya.

Regresi Nonlinear: Metode Gauss-Newton

Masalah

Cocokkan $y_i = f(x_i; a_0, \dots, a_m) + \varepsilon_i$, misalnya

$$f(x) = a_0 \left(1 - e^{-a_1 x} \right).$$

Parameter masuk secara nonlinear, sehingga persamaan normalnya tidak lagi linear.

Linearisasi terhadap parameter

Ekspansi Taylor orde satu di sekitar tebakan $\{A\}_j$:

$$f(x_i)_{j+1} \approx f(x_i)_j + \frac{\partial f(x_i)_j}{\partial a_0} \Delta a_0 + \frac{\partial f(x_i)_j}{\partial a_1} \Delta a_1,$$

sehingga $\{D\} = [Z_j]\{\Delta A\} + \{E\}$ dengan

$$[Z_j] = \left[\frac{\partial f_i}{\partial a_k} \right], \quad \{D\} = \left\{ y_i - f(x_i)_j \right\}.$$

SPL yang diselesaikan tiap langkah

$$\left([Z_j]^T [Z_j] \right) \{\Delta A\} = [Z_j]^T \{D\}$$

lalu perbarui

$$a_{k,j+1} = a_{k,j} + \Delta a_k.$$

Kriteria berhenti

$$|e_{a_k}| = \left| \frac{a_{k,j+1} - a_{k,j}}{a_{k,j+1}} \right| 100\% < \varepsilon_s.$$

Struktur yang sama sekali lagi

Bandingkan dengan SPNL: di sana $A \Delta X = -f$, di sini $[Z]^T [Z] \{\Delta A\} = [Z]^T \{D\}$. Keduanya menyelesaikan SPL untuk memperoleh langkah koreksi.

Contoh Gauss-Newton: Iterasi Pertama

Data dan model

$$f(x) = a_0 \left(1 - e^{-a_1 x}\right), \quad a_0^{(0)} = a_1^{(0)} = 1.$$

x	0.25	0.75	1.25	1.75	2.25
y	0.28	0.57	0.68	0.74	0.79

Turunan parsial

$$\frac{\partial f}{\partial a_0} = 1 - e^{-a_1 x}, \quad \frac{\partial f}{\partial a_1} = a_0 x e^{-a_1 x}.$$

$$[Z_0] = \begin{bmatrix} 0.2212 & 0.1947 \\ 0.5276 & 0.3543 \\ 0.7135 & 0.3581 \\ 0.8262 & 0.3041 \\ 0.8946 & 0.2371 \end{bmatrix}, \quad \{D\} = \begin{bmatrix} 0.0588 \\ 0.0424 \\ -0.0335 \\ -0.0862 \\ -0.1046 \end{bmatrix}$$

Susun dan selesaikan SPL

$$[Z_0]^T [Z_0] = \begin{bmatrix} 2.3193 & 0.9489 \\ 0.9489 & 0.4404 \end{bmatrix}, \quad [Z_0]^T \{D\} = \begin{bmatrix} -0.1533 \\ -0.0365 \end{bmatrix}$$

$$\{\Delta A\} = \begin{bmatrix} -0.2714 \\ 0.5019 \end{bmatrix}$$

Perbarui parameter

$$\begin{Bmatrix} a_0 \\ a_1 \end{Bmatrix}_1 = \begin{Bmatrix} 1.0 \\ 1.0 \end{Bmatrix} + \begin{Bmatrix} -0.2714 \\ 0.5019 \end{Bmatrix} = \begin{Bmatrix} 0.7286 \\ 1.5019 \end{Bmatrix}$$

Aktivitas kelas

Lakukan iterasi ke-2, hitung $|e_{a_k}|$, lalu bandingkan S_r hasil Gauss-Newton dengan hasil regresi linear atas data yang ditransformasi. Mana yang lebih kecil, dan mengapa?

Rangkuman: Empat Topik, Satu Kerangka

Topik	Yang diselesaikan	Cara memperoleh langkah
SPL	$Ax = b$	langsung (Gauss, LU) atau iteratif (Jacobi, Gauss-Seidel)
SPNL	$F(x) = 0$	linearisasi Taylor $\Rightarrow$ selesaikan $A \Delta X = -f$
Regresi linear	$\min S_r$, parameter linear	persamaan normal, sebuah SPL berukuran kecil Gauss-Newton: $([Z]^T [Z]) \{\Delta A\} = [Z]^T \{D\}$
Curve fitting nonlinear	$\min S_r$, parameter nonlinear	

Tiga pertanyaan yang selalu berlaku

1. Apa tebakan awalnya, dan mengapa masuk akal?
2. Bagaimana galat diukur dan kapan iterasi dihentikan?
3. Apakah metodenya dijamin konvergen untuk masalah ini?

Menuju UTS dan project

UTS mencakup **pencarian akar dan SPL**. SPNL serta pemodelan data-driven merupakan pengayaan yang menjadi jembatan menuju project MATLAB dan draft artikel.

Tugas A — SPL

Perhatikan SPL dari model tiga reaktor

$$120c_1 - 20c_2 = 400$$

$$80c_1 - 80c_2 = 0$$

$$40c_1 + 60c_2 - 120c_3 = -200$$

1. Tentukan solusinya secara analitik.
2. Kerjakan dengan metode Jacobi dan Gauss-Seidel, minimal 3 langkah, sertakan ε_a tiap komponen.
3. Ulangi di Excel dan sajikan plot ε_a terhadap iterasi untuk kedua metode.
4. Periksa dominansi diagonal dan komentari kecepatan konvergensi yang Anda amati.

Tugas B — Pencocokan Kurva

Gunakan data pada slide contoh regresi.

1. Lengkapi tabel, susun persamaan normal, tentukan a dan b .
2. Hitung S_t , S_r , dan r^2 , lalu tafsirkan nilainya.
3. Cocokkan data $f(x) = a_0(1 - e^{-a_1x})$ pada slide Gauss-Newton sampai dua iterasi.
4. Bandingkan dengan hasil linearisasi dan jelaskan perbedaannya.

Pengumpulan

Melalui e-learning. Sertakan perhitungan, berkas Excel atau kode MATLAB, tabel galat, dan interpretasi singkat — bukan hanya angka akhir.

Rujukan dan Persiapan Pertemuan Berikutnya

Rujukan utama

Chapra, S. C. & Canale, R. P., *Numerical Methods for Engineers*. Bagian yang relevan:

- ▶ SPL dan metode iteratif (Gauss-Seidel).
- ▶ Sistem persamaan nonlinear dan Newton-Raphson multivariabel.
- ▶ Regresi least-square, koefisien determinasi.
- ▶ Regresi nonlinear (Gauss-Newton) dan linearisasi.

Pertemuan 3–4: bedah jurnal

Siapkan artikel yang memakai SPL, SPNL, fixed point, optimisasi, atau model data-driven. Untuk tiap artikel telaah: masalah, ekspresi matematis, metode dan tebakan awal, hasil beserta galat, serta kritik atas pilihan metodenya.

Presenter acak

Semua mahasiswa harus siap; presenter ditentukan secara acak dan semua akan mendapat giliran.